


COVID-19 CT Images Segmentation

Carlos, Dongju, Jorge, Sebastian, Evan

Segmentación de lesiones COVID-19 en CT:

- **Objetivo.** Desarrollar un modelo de segmentación semántica capaz de clasificar cada píxel de cortes axiales de tomografía computarizada (CT) en cuatro clases: Ground Glass, Consolidation, Lungs y Background. A diferencia de clasificación o detección, la segmentación genera una máscara del mismo tamaño que la imagen, permitiendo localizar y cuantificar las regiones afectadas.
- Ground Glass: lesión de apariencia gris tenue donde todavía pueden observarse estructuras pulmonares.
- Consolidation: región de mayor densidad donde el espacio aéreo está ocupado por líquido o material inflamatorio. Estas dos lesiones pueden ser difíciles de distinguir debido principalmente a sus diferencias de densidad.



Dataset:

- Trabajamos con dos fuentes de imágenes CT de 512 × 512 píxeles. Radiopaedia contiene 829 slices provenientes de volúmenes completos, mientras que MedSeg contiene 100 slices seleccionados individualmente. El conjunto de prueba contiene 10 slices MedSeg sin máscara. Las imágenes contienen un canal de intensidad HU y las máscaras cuatro canales one-hot, uno por clase.

Clase	Radiopaedia	MedSeg
Ground Glass	1.02%	4.56%
Consolidation	0.23%	2.25%
Lungs	14.50%	19.99%
Background	84.26%	73.20%

- La consolidación representa solamente 0.23% de los píxeles de Radiopaedia, frente a 84.26% de background. Por ello, accuracy sería una métrica engañosa y el desbalance debe considerarse durante el entrenamiento


Preprocesamiento y Data Augmentation:

- La augmentación genera variaciones de las imágenes de entrenamiento para reducir overfitting, pero las transformaciones deben conservar la anatomía y la información diagnóstica de las CT. Por ello se utilizan transformaciones geométricas e intensidades moderadas, mientras que transformaciones anatómicamente imposibles como VerticalFlip son descartadas.

Transformación	Propósito	Parametros	p
Rotation	Variación de posición	+/-20	0.5
RandomSizedCrop	Escala/campo de visión	384–512 px → 512 (zoom ×1.0–1.33)	0.5
HorizontalFlip	Simetría izquierda-derecha	Sobre eje Y	0.5
RandomBrightnessContrast	Variación lineal de intensidad y contraste	±0.15 (≈ ±300 HU)	0.3
Gamma	Variación no lineal de intensidad	0.8 – 1.2	0.3

Arquitectura U-Net:

- Se implementó una U-Net, arquitectura encoder-decoder diseñada para segmentación biomédica. El encoder reduce progresivamente la resolución espacial mientras aumenta el número de canales, permitiendo aprender representaciones cada vez más abstractas. El decoder recupera la resolución original mediante convoluciones transpuestas.
- Skip connections: conectan directamente encoder y decoder para recuperar información espacial fina perdida durante el downsampling. De esta forma, el decoder combina información semántica profunda con la localización precisa de bordes. La capa final 1×1 transforma 64 canales en los 4 logits, uno por clase.



COVID-19 CT Images Segmentation

Carlos, Dongju, Jorge, Sebastian, Evan


Componente	Configuración
Tipo	U-Net 2D (Ronneberger et al., 2015)
Niveles de profundidad	4 + bottleneck
Canales base	64
Bloque	Conv 3×3 → BatchNorm → ReLU, ×2
Reducción	MaxPool 2×2
Expansión	ConvTranspose 2×2, stride 2
Skip connections	Concatenación en los 4 niveles
Capa final	Conv 1×1 → 4 canales, sin activación
Parámetros totales	31.042.564
Parámetros en el bottleneck	14.161.920 (45.6 %)

Entrenamiento:


- El modelo U-Net se entrenó durante 30 épocas utilizando el optimizador Adam con una tasa de aprendizaje inicial de 3×10^{-4} y un scheduler CosineAnnealingLR para reducirla progresivamente. Se utilizó una función de pérdida combinada de Cross Entropy + Dice Loss, donde Dice se calculó sobre las tres clases anatómicas, excluyendo el fondo. Debido al desbalance del conjunto de datos, se aplicó oversampling de MedSeg, aumentando su representación aproximada del 10% al 35% de cada época. El entrenamiento se realizó con lotes de 16 imágenes. El mejor modelo se guardó automáticamente de acuerdo con el promedio del Dice de Ground Glass y Consolidation.

Resultado:

- El mejor modelo alcanzó un Dice promedio de 0.5469 para las dos clases de lesión, correspondiente al mejor checkpoint durante las 30 épocas. En esta evaluación se obtuvo un Dice de 0.5850 para Ground Glass y 0.5088 para Consolidation. Durante las últimas épocas, Ground Glass llegó hasta 0.6753 y Consolidation hasta 0.4112, mientras que la segmentación de Lungs y Background se mantuvo considerablemente más alta, alcanzando aproximadamente 0.92 y 0.99, respectivamente. Los resultados muestran una mayor dificultad para segmentar las lesiones que las regiones pulmonares y el fondo.



Mejor modelo	Epoca 15
Clase	Dice
Ground glass	0.5850
Consolidation	0.5088
Lungs other	0.9136
Background	0.9890
Media de lesiones	0.5469



Entrada	512 × 512 × 1 canal · ventana HU [−1500, 500] → [0, 1]
Arquitectura	U-Net 2D, 4 niveles · 31.042.564 parámetros
Canales	64 → 128 → 256 → 512 → 1024 → 512 → 256 → 128 → 64
Activación oculta	ReLU
Normalización	BatchNorm2d
Reducción / Expansión	MaxPool 2×2 / ConvTranspose 2×2
Salida	Conv 1×1 → 4 logits → softmax → argmax
Pérdida	CrossEntropy + soft Dice (batch-wise, sin fondo)
Optimizador	Adam, lr inicial 3×10^{-4}
Scheduler	CosineAnnealing ($3e-4 \rightarrow 8e-7$)
Épocas / Batch	30 / 16
Balanceo	WeightedRandomSampler, MedSeg ×5 (10 % → 35 %)
Hardware	NVIDIA Tesla T4 · 109 s/época · 55 min totales
Semilla	42